



İST489-ZAMAN SERİLERİ ANALİZİ DERSİ DÖNEM ÖDEVİ

HAZIRLAYAN: HANDE NUR BANUŞ 2210329067

DERS SORUMLUSU: Prof. Dr. CEM KADILAR

DERSİN ASİSTANI: Arş. Gör. Dr. CEREN ÜNAL AKDENİZ

16.12.2024

Veri seti hakkında bilgi:


Basel şehrine ait 4 günlük, 24 saatlik hava durumu bilgisini içeriyor.

Gözlem sayısı :96

Değişken sayısı:1, Sıcaklık

Periyot:12

Çözümlemeye başlamadan önce yapılacak ilk şey zaman serisi grafiği oluşturmaktır.



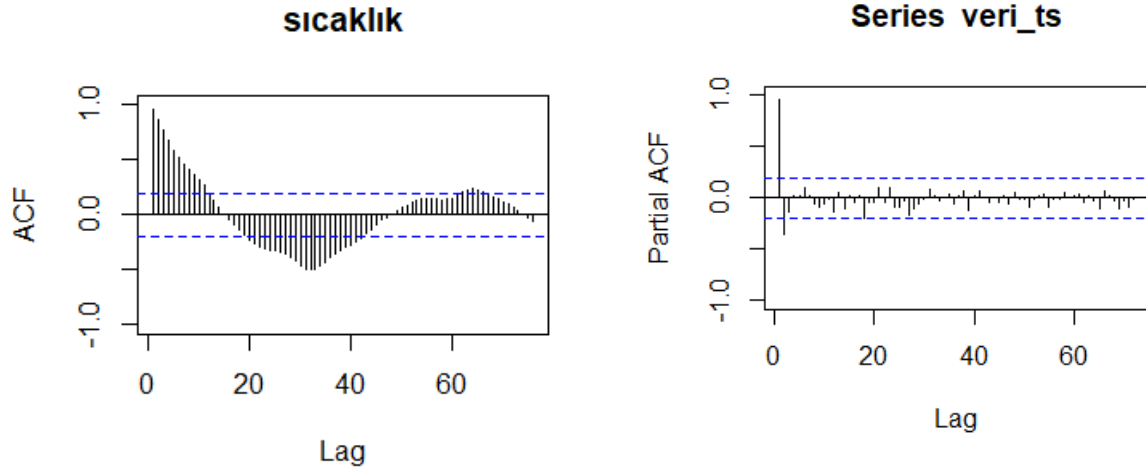
Trend: Bir serinin belli bir zaman boyunca artması veya azalması hareketine denir.

Mevsimsellik: Seride senelik, aylık, haftalık gibi faktörlerden etkilenecek oluşan kavramdır.

Bu grafikte belirli aralıklarda artış olmuş. Trend ve mevsimsellik için kesin bilgiye ACF (otokorelasyon fonksiyonu) grafiğinden ulaşırız.

Otokorelasyon Fonksiyonu: Korelasyon, iki değişken arasındaki doğrusal ilişkinin ölçüsünü ölçerken, otokorelasyon bir zaman dizisinin gecikmeli değerleri arasındaki doğrusal ilişkiyi ölçer.

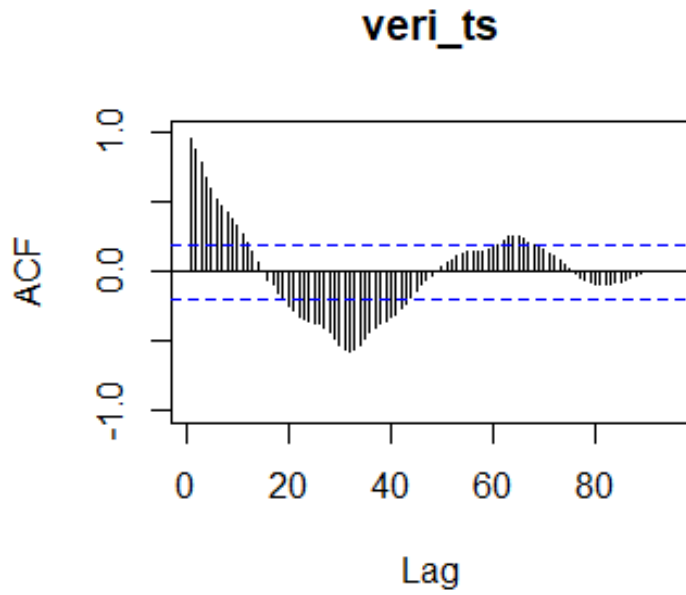
Kısmi Otokorelasyon Fonksiyonu: Zaman serileri analizinde, kısmi otokorelasyon fonksiyonu (PACF), bir zaman dizisinin kendi gecikmeli değerleri ile kısmi korelasyonunu verir ve tüm kısa süreli gecikmelerde zaman serilerinin değerlerini kontrol eder.




ACF grafiğinde ilk 4 gecikme sınır dışında olduğunda trend olduğunu söyleyebiliriz. Aynı zamanda bazı yerlerde yükselmesi/azalması mevsimsel seri içerdiğini de gösteriyor.

Periyot bulma:

Serinin periyoduna sahip mevsimsel bileşen serisinin ACF grafiğinden periyodu bulalım:



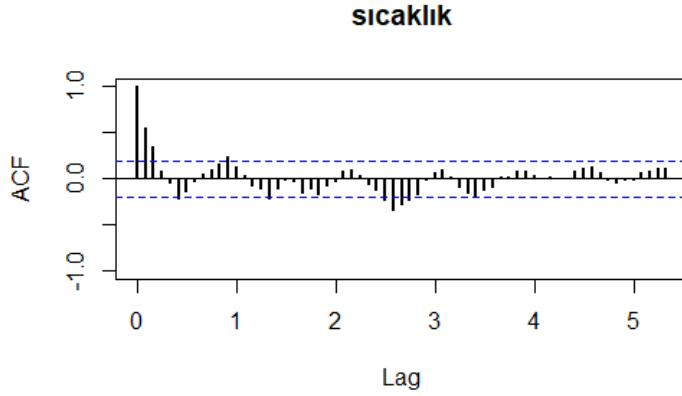
Yine periyot net olarak belirli değil, 1.dereceden fark alıp periyoda bakalım.



Pozitif taraftaki gecikmeler incelendiğinde periyodun 12 olduğu görülüyor.

DURAĞANLAŞTIRMA

Verimizin trende ve mevsimselliğe sahip olduğunu gördük. Ama veride baskın bir mevsimsellik yok. Periyot zor belirlendi. O yüzden veriyi durağanlaştırmak için mevsimsel fark almaya gerek yok. Birinci dereceden fark (trend) alınır.



AYRIŞTIRMA YÖNTEMLERİ

TOPLAMSAL MODEL:

Serinin merkezsel hareketli ortalama serisi bulunur. Orijinal seriden merkezsel hareketli ortalama serisi çıkartılarak mevsimsel bileşen bulunur. Germe sayısı için periyot tercih edilir. 12 tane ortalama değer çıkar.

```

> colMeans(donem_ort, na.rm = T)
[1] 0.46529761 0.59470251 0.48874999 0.22363109 -0.13136906 -0.35202396 -0.34047633
[8] -0.28434524 -0.20803572 -0.04666681 0.05410728 0.19494061
> sum(colMeans(donem_ort, na.rm = T))
[1] 0.658512
> mean(colMeans(donem_ort, na.rm = T))
[1] 0.054876

```

$\bar{M}_1 = 0.46529761$, $\bar{M}_2 = 0.59470251$, ..., $\bar{M}_{11} = 0.05410728$, $\bar{M}_{12} = 0.19494061$

$\bar{\bar{M}} = 0.054876 \rightarrow 12$ değerin ortalamalarının ortalaması

Buradan mevsimsel endeks değerleri:

```

> endeks
[1] 0.4104216101 0.5398265149 0.4338739970 0.1687550923 -0.1862450565 -0.4068999554
[7] -0.3953523304 -0.3392212411 -0.2629117173 -0.1015428065 -0.0007687173 0.1400646101

```

Mevsimsel Endeks Serisi:

$M_1 = 0.46529761 - (0.054876) = \mathbf{0.4104}$

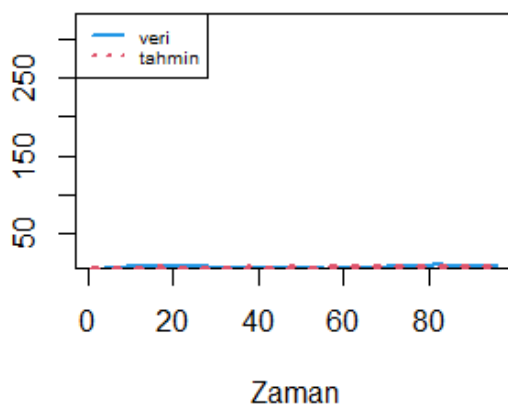
$M_2 = 0.59470251 - (0.054876) = \mathbf{0.5398}$

İndeks değerleri 12'de bir tekrar ederek gözlem sayısına (96) kadar ulaşan seridir.

Modelin güvenirliliği


Toplamsal modelin ele alınan seri üzerinde geçerli bir model olup olmadığını kontrol edelim:

Orijinal seri ile tahmin serisinin uyumu:



Tahmin ile orijinal seri uyumlu gözüküyor. Ama bu uyum istatistiksel olarak geçerli olduğunu söyleyemez. Hata serisi incelenir.

Hatalar ak gürültü mü?



```
Box-Ljung test
data: hata
X-squared = 1022, df = 42, p-value < 2.2e-16
> |
```

Ho: hatalar arasında ilişki yoktur.

Gecikmeler sınır dışında ve Box-Ljung testinden görüldüğü üzere p değerimiz 0.05 ten küçük olduğu için ilişki önemlidir yani hataların ak gürültü serisi olduğunu söyleyemeyiz. Hataların ak gürültü serisi olması için ilk 20 gecikmenin güven sınırları içerisinde olmasını bekleriz. Burada ACF grafiğine baktığımızda hatalar ak gürültü değildir. Serinin modellenmesi anlamlı değildir. Toplamsal modelin tahmini güvenilir değil. Çarpımsal modeli de inceleyelim.

ÇARPIMSAL MODEL

Mevsimsel bileşen, orijinal serinin merkezsel hareketli ortalama serisine bölünmesiyle bulunur. Germe sayısını yine periyot sayısı olarak girebiliriz.

```
> colMeans(donemort2, na.rm = T)
[1] 1.0683392 1.0872465 1.0679041 1.0281876 0.9771721 0.9482535 0.9498854 0.9553135 0.9649812
[10] 0.9878144 1.0026249 1.0258031
> sum(colMeans(donemort2, na.rm = T))
[1] 12.06353
> #ortalamların ortalaması
> mean(colMeans(donemort2, na.rm = T))
[1] 1.005294
```

$\bar{M}_1=1.06833$, $\bar{M}_2=1.0872$, $\bar{M}_{12}=1.0258$

$\bar{\bar{M}}= 1.005294 \rightarrow 12$ değerin ortalamasının ortalaması

Mevsimsel endeks değerleri:


```
> endeks2<- colMeans(donemort2, na.rm = T)/mean(colMeans(donemort2, na.rm = T))
> endeks2
[1] 1.0627134 1.0815211 1.0622806 1.0227732 0.9720264 0.9432601 0.9448833 0.9502829 0.9598997
[10] 0.9826126 0.9973452 1.0204013
`
```

$M1 = 1.0683392 - (1.005294) = 1.0627134....$

Modelin güvenirliliği


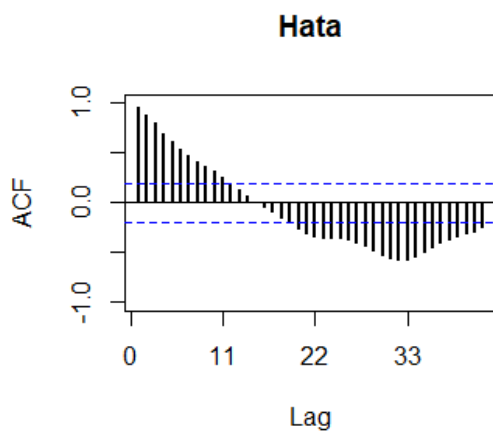
Çarpımsal modelin ele alınan seri üzerinde geçerli bir model olup olmadığını kontrol edelim.

Orijinal seri ile tahmin serisinin uyumu:



Uyumlu gözüküyorlar. Hata serisi incelenir.

Hatalar ak gürültü mü?



Box-Ljung test

```
data: hata2
X-squared = 1021.1, df = 42, p-value < 2.2e-16
```

Ho: hatalar arasında ilişki yoktur.

Gecikmeler sınır dışında ve Box-Ljung testinden görüldüğü üzere p değerimiz 0.05 ten küçük olduğu için ilişki önemlidir yani hataların ak gürültü serisi olduğunu söyleyemeyiz. Çarpımsal model de anlamlı çıkmadı. Elimizdeki veri, ayrıştırma yöntemleri ile modellenmeye uygun değil.

REGRESYON ANALİZİ

TOPLAMSAL MODEL

Sıcaklık veri seti, hem trende hem de mevsimselliğe sahip olduğu için regresyon modelinin “t”, “sinüs” ve “kosinüs” terimlerini içermesi gerekir.

$12/2=6$ en fazla 6 harmonik hareket incelenebilir.

96 gözlem olduğu için 1’den 96’ya $t \leftarrow 1:1:96$ şeklinde t terimini oluştururuz.

Sinüs ve kosinüs terimlerini de formülden;

$\sin 1 \leftarrow \sin(2 \cdot 3.1416 \cdot t / 12)$, $\cos 1 \leftarrow \cos(2 \cdot 3.1416 \cdot t / 12)$ şeklinde oluşturulur.

İlk Toplamsal Regresyon Modelinin Çıktısı:

```
> summary(regresyon.model1)
```

Call:

```
lm(formula = y ~ t + sin1 + cos1)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.4906	-1.1534	-0.1364	1.3247	2.5184

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.306280	0.299748	21.039	< 2e-16 ***
t	0.016869	0.005373	3.140	0.00227 **
sin1	0.206484	0.210484	0.981	0.32917
cos1	0.247624	0.209595	1.181	0.24047

Signif. codes: 0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.452 on 92 degrees of freedom

Multiple R-squared: 0.1147, Adjusted R-squared: 0.08584

F-statistic: 3.974 on 3 and 92 DF, p-value: 0.01036


```
> ##durbin-watson testi
> dwtest(y~t+sin1+cos1)
```

Durbin-Watson test

```
data: y ~ t + sin1 + cos1
DW = 0.059106, p-value < 2.2e-16
alternative hypothesis: true autocorrelation is greater than 0
```

H0: katsayılar anlamsız.

Model anlamlı ($p=0.0103<0.05$), t ve sabit sayı da anlamlı ama sin1 ve cos1 p değerleri 0.05'ten büyük olduğundan H0 reddedilemez. Katsayılar önemli değil. Dolayısıyla orijinal seri ile tahmin serisinin uyumu ve hataların ak gürültü olup olmadığını incelemeye gerek yoktur. 2.harmoniklere geçilmez. Çarpımsal modele bakalım.

ÇARPIMSAL MODEL

Çarpımsal modelde sinüs ve kosinüs terimleri formülden;

$s1 <- t \cdot \sin(2 \cdot 3.1416 \cdot t / 11)$,

$c1 <- t \cdot \cos(2 \cdot 3.1416 \cdot t / 11)$ şeklinde yazılır.

İlk Çarpımsal Regresyon Modelinin Çıktısı:

```
> summary(regresyon.model2)
```

Call:

```
lm(formula = y ~ t + s1 + c1)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-2.24694	-1.23449	-0.09836	1.25015	2.43798

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	6.307825	0.299201	21.082	< 2e-16	***
t	0.017004	0.005369	3.167	0.00209	**
s1	0.005070	0.003802	1.334	0.18564	
c1	0.002685	0.003726	0.721	0.47301	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.452 on 92 degrees of freedom

Multiple R-squared: 0.1137, Adjusted R-squared: 0.08477

F-statistic: 3.933 on 3 and 92 DF, p-value: 0.01089

```
> ##durbin-watson testi
> dwtest(y~t+s1+c1)
```

Durbin-watson test

```
data: y ~ t + s1 + c1
DW = 0.060907, p-value < 2.2e-16
alternative hypothesis: true autocorrelation is greater than 0
```

H0: katsayılar anlamsızdır.

Model anlamlı ($p:0.0108 < 0.05$), t ve sabit sayı da anlamlı ama s1 ve c1 p değerleri 0.05'ten büyük olduğundan H0 reddedilemez. Katsayılar önemli değil. Dolayısıyla orijinal seri ile tahmin serisinin uyumu ve hataların ak gürültü olup olmadığını incelemeye gerek yoktur. 2.harmoniklere geçilmez. Sonuç olarak elimizdeki sıcaklık serisi ile ayrıştırma yönteminde olduğu gibi regresyon analizinde de güvenilir tahminler elde edilememiştir. Üstel düzleştirme yöntemlerine bakalım.

ÜSTEL DÜZLEŞTİRME YÖNTEMİ

Trende ve mevsimsel dalgalanmaya sahip serilerin tahmininde **winters üstel düzleştirme yöntemi** kullanılmaktadır.

Toplamsal winters üstel düzleştirme yöntemi

```
> summary(winters1)
ETS(A,Ad,A)

Call:
ets(y = veri_ts, model = "AAA")

Smoothing parameters:
alpha = 0.9998
beta  = 0.1295
gamma = 1e-04
phi   = 0.924

Initial states:
l = 3.9328
b = 0.3444
s = 0.0904 -0.0676 -0.1633 -0.27 -0.3279 -0.3097
    -0.3376 -0.1564 0.1769 0.4339 0.5432 0.388

sigma: 0.3313

      AIC      AICC      BIC
243.3623 252.2454 289.5206

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.008707405 0.3005437 0.2461701 -0.05042606 3.619537 0.1576449 0.3338535
```

Çıktıya göre ortalama düzeyin başlangıç değeri : 3.9328

Eğimin başlangıç değeri: 0.3444

Mevsimsel terimin başlangıç değerleri:


$M_1(0)$: 0.0904, $M_2(0)$:-0.0676, $M_3(0)$:-0.27 , , $M_{11}(0)$: 0.5432 , $M_{12}(0)$: 0.388

Bu başlangıç değerleri kullanılarak optimal düzleştirme katsayıları;

$\alpha = 0.9998$, $\beta = 0.1295$, $\gamma = 1e-04 \cong 0$, $\phi = 0.924$ ve ,


\sqrt{HKO} =RMSE=0.30054 olarak bulunmuş. Bu katsayılar kullanılarak serinin tahmin değerleri ve hata serisi oluşturulacaktır.

Orijinal seri ile tahmin serisinin uyumu:



Tahmin ile orijinal seri uyumlu gözüküyor. Ama bu uyum istatistiksel olarak geçerli olduğunu söyleyemez. Hata serisi incelenir.

Hatalar ak gürültü mü?



Box-Ljung test

```
data: hata_winters
X-squared = 178.59, df = 52, p-value = 8.882e-16
```

Ho: hatalar arasında ilişki yoktur.

Gecikmelerin bazıları sınır dışında ve Box-Ljung testinden görüldüğü üzere p değerimiz 0.05 ten küçük olduğu için ilişki önemlidir yani hataların ak gürültü serisi olduğunu söyleyemeyiz. Çarpımsal winters yöntemine bakalım.

ÇARPIMSAL WINTERS YÖNTEMİ

```
> summary(winters2)
ETS(M,Ad,M)

Call:
ets(y = veri_ts, model = "MAM")

Smoothing parameters:
alpha = 0.992
beta  = 0.046
gamma = 0.0061
phi   = 0.9629

Initial states:
l = 3.6143
b = 0.5956
s = 0.9893 0.9575 0.9441 0.9424 0.9529 0.9678
    0.9846 1.0045 1.0335 1.0677 1.0866 1.0692

sigma: 0.0518

      AIC      AICC      BIC
261.0991 269.9822 307.2574

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.06359483 0.3464091 0.2679066 -0.8730921 3.781582 0.1715648 0.4244504
```

Çıktıya göre ortalama düzeyin başlangıç değeri:3.6143

Eğimin başlangıç değeri: 0.5956

Mevsimsel terimin başlangıç değerleri:

$M_1(0)$: 0.9893, $M_2(0)$: 0.9575, $M_3(0)$: 0.9441, $M_4(0)$: 0.9424

$M_5(0)$: 0.9529, $M_6(0)$: 0.9678, $M_7(0)$: 0.9846, $M_8(0)$: 1.0045


$M_9(0)$: 1.0335, $M_{10}(0)$: 1.0677, $M_{11}(0)$: 1.086, $M_{12}(0)$: 1.0692

Bu başlangıç değerleri kullanılarak optimal düzleştirme katsayıları;

$\alpha = 0.992$, $\beta = 0.046$, $\gamma = 0.0061$, $\phi = 0.9629$ ve ,


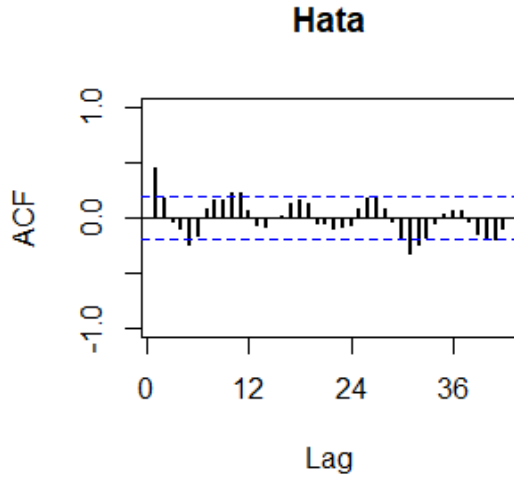
$\sqrt{HKO} = RMSE = 0.3464091$ olarak bulunmuş. Bu katsayılar kullanılarak serinin tahmin değerleri ve hata serisi oluşturulacaktır.

Orijinal seri ile tahmin serisinin uyumu:



Tahmin ile orijinal seri uyumlu gözüküyor. Ama bu uyum istatistiksel olarak geçerli olduğunu söyleyemez. Hata serisi incelenir.

Hatalar ak gürültü mü?



Ho: hatalar arasında ilişki yoktur.

Box-Ljung test


```
data: hata_winters2
x-squared = 169.32, df = 52, p-value = 2.409e-14
```

Gecikmelerin bazıları sınır dışında ve Box-Ljung testinden görüldüğü üzere p değerimiz 0.05 ten küçük olduğu için ilişki önemlidir yani hataların ak gürültü serisi olduğunu söyleyemeyiz. Hatalar ak gürültü olsaydı öngörü yapardık. Sıcaklık veri seti üstel düzleştirme yöntemiyle de tahmin edilmesi güvenilir değil.

BOX-JENKINS MODELLERİ

Sıcaklı serisi 1.derece farkta trendden arındırılmıştı ve mevsimselliğin baskınlığı kalmamıştı. Seri durağanlaştığına göre işleme başlayabiliriz.

PACF ve ACF beraber değerlendirildiğinde,



PACF, ACF grafiğine göre daha hızlı azalmış. Model otoregresyon modeli olmaktadır. ($q=0$). PACF grafiğinde ilk üç gecikmeden bir gecikmeye ait ilişki önemli olduğundan p maksimum 1'dir. ACF grafiğinde ise ilk üç gecikmenin üçü de önemli olduğundan q maksimum 3'dür. 1.dereceden farkta durağanlaştığı için $d=1$, mevsimsel fark almadığımız için $D=0$ 'dır.

$s=12$ -periyot

$p=1$ - maksimum

$q=3$ – maksimum

$D=0$, $d=1$ -aynı kalır

ARIMA(0,1,0)(0,1,0) fark serisidir denenmez.

ARIMA($p, 1, q$)($P, 0, Q$)₁₂

Anlamlı çıkan modeller incelenecektir. Diğer denenen tüm modeller kodlar kısmında verilmiştir.

```

> arima1<-Arima(veri_ts, order = c(1,1,0), seasonal= c(0,0,0), include.constant=TRUE)
> coeftest(arima1)

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ar1    0.542847   0.084938  6.3911 1.647e-10 ***
drift   0.035069   0.066922  0.5240  0.6003
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary(arima1)
Series: veri_ts
ARIMA(0,1,0) with drift

Coefficients:
    drift
    0.0351
s.e.    0.0370

sigma^2 = 0.1317: log likelihood = -38.02
AIC=80.03  AICc=80.16  BIC=85.14

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 4.286657e-05 0.3591568 0.2732205 -0.03286844 3.96455 0.1749677 0.5484914

```

$H_0: \beta=0$ (katsayılar anlamlı değildir.)

$P \cong 0 < 0.05$ olduğu için katsayı anlamlıdır. Bu model kullanılabilir.

BIC=85.14 , RMSE=0.359

$ARIMA(1,1,0)(0,0,0)_{12}$

ACF>PACF OLDUĞU DURUM

O zaman model merkezsel hareketli model olur. ($p=0$)

```

> arima9<-Arima(veri_ts, order = c(0,1,1), seasonal= c(0,0,0), include.constant=TRUE)
> coeftest(arima9)

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1    0.393573   0.071944  5.4705 4.487e-08 ***
drift   0.034951   0.045641  0.7658  0.4438
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary(arima9)
Series: veri_ts
ARIMA(0,1,1) with drift

Coefficients:
    ma1  drift
    0.3936 0.0350
s.e.    0.0719 0.0456

sigma^2 = 0.1047: log likelihood = -26.68
AIC=59.37  AICc=59.63  BIC=67.03

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.000202611 0.3184897 0.2373496 0.01500372 3.403974 0.1519964 0.1482764
~ |

```

$H_0: \beta=0$ (katsayılar anlamlı değildir.)

$P \cong 0 < 0.05$ olduğu için katsayı anlamlıdır. Bu model kullanılabilir.

BIC=67.03 , RMSE=0.318

$ARIMA(0,1,1)(0,0,0)_{12}$

PACF ve ACF İKİSİNİN DE HIZLI AZALDIĞI DURUM

Bu durumda modelimiz otoregresif hareketli ortalama modeli olmaktadır.

Bu kısımda anlamlı model bulunamamıştır. Denenen tüm kombinasyonlar kodlar kısmında verilmiştir.


$ARIMA(1,1,0)(0,0,0)_{12} \rightarrow BIC=85.14, RMSE=0.359$ (arima1)

$ARIMA(0,1,1)(0,0,0)_{12} \rightarrow BIC=67.03, RMSE=0.318$ (arima9)


Eğer anlamlı çıkan ARIMA modellerinin hataları ak gürültü serisi çıkarsa bilgi kriter değeri (BIC) ve hata değeri (RMSE) en küçük olan modeli seçeriz.

Modellerin önce orijinal seri ile uyumuna bakalım. Sonra bu modellerin hata serileri incelenir.

$ARIMA(1,1,0)(0,0,0)_{12}$




$ARIMA(0,1,1)(0,0,0)_{12}$



Orijinal seri ile $ARIMA(1,1,0)(0,0,0)_{12}$ ve $ARIMA(0,1,1)(0,0,0)_{12}$ modellerinin tahmin serisi uyumlu çıkmıştır. Hataların ak gürültü olup olmadığına bakarız.

ARIMA(0,1,1)(0,0,0)₁₂ (arima9)




Gecikmelerin bazıları sınır dışında. Ak gürültü serisi değildir. Test edelim:

```
> Box.test(hata_arima9, lag = 42, type = "Ljung")  
  
Box-Ljung test  
  
data: hata_arima9  
x-squared = 77.69, df = 42, p-value = 0.0006675
```

Ho: hatalar arasında ilişki yoktur.

P=0.0006<0.05 olduğundan ak gürültü serisi değildir.

ARIMA(1,1,0)(0,0,0)₁₂ (arima1)



Gecikmelerden bazıları sınırı çok az geçmiş durumda. AK gürültü gözüküyor. Ama kesin olarak söylememiz için box-ljung testi yapılır.

Box-Ljung test

```
data: hata_arma1  
X-squared = 55.471, df = 42, p-value = 0.07959
```

H0: hatalar arasında ilişki yoktur.

$p=0.07959 > 0.05$ olduğundan hatalar ak gürültü seridir. $ARIMA(1,1,0)(0,0,0)_{12}$ modeli tercih edilir. Bu modelin tahmini istatistiksel olarak güvenilirdir. Bu model, serinin öngörü değerlerinin bulunması için uygundur.

Öngörü değerleri:

Son gözlem saat bilgisi 23.00 olduğu için öngörü değerleri bir gün sonrasının 00:00:00, 01:00:00, 02:00:00, 03:00:00, 04:00:00, 05:00:00 saatlerini tahmin edecek.

```
> son_veri<- as.data.frame(ongoru[["mean"]])  
> son_veri<- cbind(c("00:00:00", "01:00:00", "02:00:00",  
+                  "03:00:00", "04:00:00", "05:00:00"), son_veri)  
> names(son_veri)<-c("saat", "ongoru")  
> son_veri  
      saat      ongoru  
1 00:00:00 7.517991  
2 01:00:00 7.554513  
3 02:00:00 7.590371  
4 03:00:00 7.625868  
5 04:00:00 7.661170  
6 05:00:00 7.696365
```

Son gözlem: 11.01.2023 23:00:00 – 7.480245

Öngörü1: 12.01.2023 00:00:00 – 7.517991

Öngörü2: 12.01.2023 01:00:00 – 7.554513

Öngörü3: 12.01.2023 02:00:00 – 7.590371

Öngörü4: 12.01.2023 02:00:00 – 7.625868

Öngörü5: 12.01.2023 02:00:00 – 7.661170

Öngörü6: 12.01.2023 02:00:00 – 7.696365

KODLAR

```
rm(list = ls())

> library(readxl)

> veri<- read_excel("C:/Users/HANDENUR/Downloads/zamanserisi-veri.xlsx")

> library(fpp)

> library(forecast)

> #zaman serisi grafigi cizelim.

> ts.plot(veri_ts,gpars=list(xlab="Zaman", ylab="Basel hava durumu"))

> #ACF ve PACF grafiklerini cizdirelim:

> Acf(veri_ts, lag.max = 76, ylim=c(-1,1), lwd=1)

> Pacf(veri_ts, lag.max = 72, ylim=c(-1,1), lwd=1)

#trent mevcut. sıcaklık serisinin trent bileсени regresyon analizi yardimi ile olusturulur.

> veri_trent<-tslm(veri_ts~trend)

> #fitted values=orijinal serinin trent bileсени

> periyot<- veri_ts-veri_trent[["fitted.values"]] #serinin periyoduna sahip mevsimsel bileşen
serisi

> #veya

> #periyot<- veri_ts-veri_trent$fitted.values

> #serinin periyoduna sahip mevsimsel bileşen serisinin ACF grafiginden periyodu bulalım:

> Acf(periyot,lag.max = 96, ylim=c(-1,1), lwd=1)

#1.fark alarak periyodu görelim.

> acf(diff(veri_ts),lag.max = 42,ylim=c(-1,1),lwd=2) #periyot:12

> #veri_ts periyot bilgiside girilsin

> veri_ts <- ts(veri,frequency = 12)

#duraganlastirma-fark alma

> fark1<-(diff(veri_ts))

> acf(fark1,lag.max = 64 ,ylim=c(-1,1),lwd=2) #1.derece fark

#AYRISTIRMA YONTEMLERİ - #TOPLAMSAL

> #merkezzsel hareketli ortalama serisi

> veri1_ts<- ma(veri_ts, order =12, centre = TRUE)
```

```

> #order: germe sayisidir. periyot degeDeri yaz1labilir

> #germe sayisi arttikca seri duzlesir.

> #Mevsimsel bileşenin bulunusu (hata terimi de mevcut)

> mevsim<- veri_ts-veri1_ts

#Mevsim serisinin ortalamalari

> donem_ort<-t(matrix(data=mevsim, nrow = 12))

> colMeans(donem_ort, na.rm = T)

> sum(colMeans(donem_ort, na.rm = T))

> mean(colMeans(donem_ort, na.rm = T))

> #mevsimsel endeks degerlerinin bulunusu

> endeks<- colMeans(donem_ort, na.rm = T)-mean(colMeans(donem_ort, na.rm = T))

> #endeks degerlerini seri boyunca yazdirma islemi

> indeks<- matrix(data = endeks, nrow = 96 , byrow = TRUE)

#trent bileşeni bulal1m (hata terimi de mevcut)

> trenthata<- veri_ts-indeks

#seriyi hatadan arindirmak icin trenthata serisine dogrusal regresyon islemi uygulanir.

> trent<-tslm(trenthata~trend)

> #ciktida yer alan fitted values orijinal serinin trent bileşenidir.

> #tahmin serisini bulalim: (mevsimsel endeks+saf trent serisi)

> tahmin<- indeks+trent[["fitted.values"]]

> #hata serisini bulalim:

> hata<- veri_ts-indeks-trent[["fitted.values"]]

> #####Modelin Guvenilirliđi#####

> #Toplamsal modelin ele alinan seri uzerinde gecerli bir model olup olmadigini kontrol edelim

> #orijinal seri ile tahmin serisinin uyumu

> plot( window(veri_ts), xlab="Zaman", ylab="",lty=1, col=4, lwd=2, ylim=c(19,320))

> lines( window(tahmin) ,lty=3,col=2,lwd=3)

> legend("topleft",c(expression(paste(veri ))), expression(paste(Tahmin ))),

lwd=c(2,2),lty=c(1,3), cex=0.6, col=c(4,2))

```

```

> Acf(hata, main="Hata", lag.max = 42, ylim=c(-1,1), lwd=2)

> Pacf(hata,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=2)

> Box.test(hata, lag = 42, type = "Ljung")

#CARPiMSAL AYRIŞTIRMA YÖNTEMİ###

> #mevsimsel bileşeni bulunması (Zt/MHO) (hata terimi de mevcuttur)

> mevsim2 <- veri_ts/veri1_ts

> donemort2<-t(matrix(data=mevsim2, nrow = 12))

> colMeans(donemort2, na.rm = T)

> sum(colMeans(donemort2, na.rm = T))

> mean(colMeans(donemort2, na.rm = T))

> endeks2<- colMeans(donemort2, na.rm = T)/mean(colMeans(donemort2, na.rm = T))

> indeks2<- matrix(data = endeks2, nrow = 96)

> #trent serisi (hata da mevcuttur) (orijinal seri/mevsimsel endeks serisi)

> trenthata2<- veri_ts/indeks2

#hatadan arındırma işlemi

> trent2<- tslm(trenthata2~trend)

> tahmin2<- indeks2*trent2[["fitted.values"]] #tahmin=endeks*orijinal serinin trent bileşeni

> hata2<- veri_ts-tahmin2

#orijinal seri ile tahmin serisinin uyumu

> plot( window(veri_ts), xlab="Zaman", ylab="",lty=1, col=4, lwd=2)

> lines( window(tahmin2),lty=3,col=2 ,lwd=2)

> legend("topleft",c(expression(paste(veri ))),expression(paste(tahmin ))),
+ lwd=c(2,2),lty=c(1,3), cex=0.6, col=c("blue","pink"))

> #hatalar akgurultu mu?

> Acf(hata2,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=2)

> Pacf(hata2,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=2)

> Box.test(hata2, lag = 42, type = "Ljung")

###REGRESYON ANALİZİ####

library(fpp)

```

```

library(stats)

library(forecast)

library(FitAR)

> t<-1:1:96 #t terimini olusturalim.1'den 96'ya

> sin1<-sin(2*3.1416*t/12)

> cos1<-cos(2*3.1416*t/12)

> veri_df<-as.data.frame(cbind(veri, t, sin1, cos1))

> names(veri_df)<- c("y", "t", "sin1", "cos1")

> attach(veri_df)

> regresyon.model1<-lm(y~t+sin1+cos1)

> summary(regresyon.model1)

> dwtest(y~t+sin1+cos1)

> s1<-t*sin(2*3.1416*t/12) #ÇARPIMSAL

> c1<-t*cos(2*3.1416*t/12)

> veri_df2<-as.data.frame(cbind(veri, t, s1, c1))

> names(veri_df2)<- c("y", "t", "s1", "c1")

> attach(veri_df2)

> regresyon.model2<-lm(y~t+s1+c1)

> summary(regresyon.model2)

> dwtest(y~t+s1+c1)

> #ÜSTEL DÜZLEŞTİRM- TOPLAMSAL WINTERS MODEL

> Winters1<- ets(veri_ts, model = "AAA")

> summary(Winters1)

> tahmin_winter<- Winters1[["fitted"]]

> plot( window(veri_ts), xlab="Zaman", ylab="",lty=1, col=4, lwd=2)

> lines( window(tahmin_winter) ,lty=3,col=2,lwd=3)

> legend("topleft",c(expression(paste(Orjinalseri)),expression(paste(Winters1Tahmin))),
+   lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))

> hata_winters<-Winters1[["residuals"]]

```

```

> Acf(hata_winters,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=2)
> Pacf(hata_winters,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=2)
> Box.test(hata_winters, lag = 52, type = "Ljung")
> #CARPIMSAL WINTERS
> Winters2<- ets(veri_ts, model="MAM")
> summary(Winters2)
> tahmin_winter2<- Winters2[["fitted"]]
> plot( window(veri_ts), xlab="Zaman", ylab="",lty=1, col=4, lwd=2)
> lines( window(tahmin_winter2) ,lty=3,col=2,lwd=3)
> legend("topleft",c(expression(paste(Orjinalseri)), expression(paste(Winters2Tahmin))),
  lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))
> hata_winters2<-Winters2[["residuals"]]
> Acf(hata_winters2,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=2)
> Pacf(hata_winters2,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=2)
> Box.test(hata_winters2, lag = 52, type = "Ljung")
> ### box-jenkins
> fark1<-(diff(veri_ts))
> acf(fark1,lag.max = 64 ,ylim=c(-1,1),lwd=2) #1.fark
> pacf(fark1,lag.max = 64 ,ylim=c(-1,1),lwd=2)
#P=0, Q=0
arma1<-Arima(veri_ts, order = c(1,1,0), seasonal= c(0,0,0), include.constant=TRUE)
coeftest(arma1) #anlamlı
summary(arma1)
#P=1,Q=0
arma2<-Arima(veri_ts, order = c(1,1,0), seasonal= c(1,0,0), include.constant=TRUE)
coeftest(arma2)
summary(arma2) #anlamsız
#P=0,Q=1
arma3<-Arima(veri_ts, order = c(1,1,0), seasonal= c(0,0,1), include.constant=TRUE)

```

```

coeftest(arima3)

summary(arima3)

#P=0,Q=2

arima4<-Arima(veri_ts, order = c(1,1,0), seasonal= c(0,0,2), include.constant=TRUE)

coeftest(arima4)

summary(arima4)

#P=0,Q=3

arima5<-Arima(veri_ts, order = c(1,1,0), seasonal= c(0,0,3), include.constant=TRUE)

coeftest(arima5)

summary(arima5) #anlamsız

#P=1,Q=1

arima6<-Arima(veri_ts, order = c(1,1,0), seasonal= c(1,0,1), include.constant=TRUE)

coeftest(arima6)

summary(arima6)

#P=1,Q=2

arima7<-Arima(veri_ts, order = c(1,1,0), seasonal= c(1,0,2), include.constant=TRUE)

coeftest(arima7)

summary(arima7)

#P=1,Q=3

arima8<-Arima(veri_ts, order = c(1,1,0), seasonal= c(1,0,3), include.constant=TRUE)

coeftest(arima8)

summary(arima8)

#ACF grafiğinin daha hızlı azaldığı durum

arima9<-Arima(veri_ts, order = c(0,1,1), seasonal= c(0,0,0), include.constant=TRUE)

coeftest(arima9) #ANLAMLI

summary(arima9)

arima10<-Arima(veri_ts, order = c(0,1,1), seasonal= c(1,0,0), include.constant=TRUE)

coeftest(arima10)

summary(arima10)

```



```

arima11<-Arima(veri_ts, order = c(0,1,1), seasonal= c(0,0,2), include.constant=TRUE)
coeftest(arima11)
summary(arima11)

arima12<-Arima(veri_ts, order = c(0,1,1), seasonal= c(0,0,3), include.constant=TRUE)
coeftest(arima12)
summary(arima12)

arima13<-Arima(veri_ts, order = c(0,1,1), seasonal= c(1,0,1), include.constant=TRUE)
coeftest(arima13)
summary(arima13)

arima14<-Arima(veri_ts, order = c(0,1,1), seasonal= c(1,0,2), include.constant=TRUE)
coeftest(arima14)
summary(arima14)

arima15<-Arima(veri_ts, order = c(0,1,1), seasonal= c(1,0,3), include.constant=TRUE)
coeftest(arima15)
summary(arima15)

#hem PACF hem de ACF nin hızlı azaldığı durum

arima16<-Arima(veri_ts, order = c(1,1,3), seasonal= c(0,0,0), include.constant=TRUE)
coeftest(arima16)
summary(arima16)

arima17<-Arima(veri_ts, order = c(1,1,3), seasonal= c(1,0,0), include.constant=TRUE)
coeftest(arima17)
summary(arima17)

arima18<-Arima(veri_ts, order = c(1,1,3), seasonal= c(0,0,1), include.constant=TRUE)
coeftest(arima18)
summary(arima18)

arima19<-Arima(veri_ts, order = c(1,1,3), seasonal= c(0,0,2), include.constant=TRUE)
coeftest(arima19)
summary(arima19)

```

```

arima20<-Arima(veri_ts, order = c(1,1,3), seasonal= c(0,0,3), include.constant=TRUE)
coeftest(arima20)
summary(arima20)

arima21<-Arima(veri_ts, order = c(1,1,3), seasonal= c(1,0,1), include.constant=TRUE)
coeftest(arima21)

arima22<-Arima(veri_ts, order = c(1,1,3), seasonal= c(1,0,2), include.constant=TRUE)
coeftest(arima22)

arima23<-Arima(veri_ts, order = c(1,1,3), seasonal= c(1,0,3), include.constant=TRUE)
coeftest(arima23)

tahmin_arima1<-arima1[["fitted"]]
hata_arima1<- arima1[["residuals"]]

tahmin_arima9<-arima9[["fitted"]]
hata_arima9<- arima9[["residuals"]]

plot( window(veri_ts),
      xlab="Zaman", ylab="",lty=1, col=4, lwd=2)
lines( window(tahmin_arima1) ,lty=3,col=2,lwd=3)
legend("topleft",c(expression(paste(veri_ts)),
                    expression(paste(Tahmin1))),
      lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))

plot( window(veri_ts),
      xlab="Zaman", ylab="",lty=1, col=4, lwd=2)
lines( window(tahmin_arima9) ,lty=3,col=2,lwd=3)
legend("topleft",c(expression(paste(veri_ts)),
                    expression(paste(Tahmin9))),
      lwd=c(2,2),lty=c(1,3), cex=0.7, col=c(4,2))

Acf(hata_arima9,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=2)
Pacf(hata_arima9,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=2)
Box.test(hata_arima9, lag = 42, type = "Ljung")

```

```
Acf(hata_arima1,main="Hata", lag.max = 42, ylim=c(-1,1), lwd=2)
Pacf(hata_arima1,main="Hata",lag.max = 42, ylim=c(-1,1), lwd=2)
Box.test(hata_arima1, lag = 42, type = "Ljung")
ongoru<-forecast(arima1,h=6)
ongoru[["mean"]]
son_veri<- as.data.frame(ongoru[["mean"]])
son_veri<- cbind(c("00:00:00","01:00:00","02:00:00",
                  "03:00:00","04:00:00","05:00:00"),son_veri)
names(son_veri)<-c("saat","ongoru")
son_veri
```

KAYNAKÇA

- SPSS ve R Uygulamalı Zaman Serileri Analizine Giriş Prof. Dr. Cem Kadılar, Doç. Dr. Hatice Öncel Çekim , 4. Baskı
- <https://ravenfo.com/2019/04/27/r-uzerinde-zaman-serisi-analizi-bolum-3-arima-modelleme/>